从零开始构建三层神经网络分类器
EuroSAT 地表覆盖图像分类实验报告

姓名：姚宗骏　　学号：25110980027

2026 年 4 月 21 日

摘要

本报告基于 EuroSAT RGB 数据集，使用纯 `NumPy` 从零实现自动微分、三层多层感知机（MLP）、带动量的随机梯度下降（SGD with Momentum）、学习率衰减、交叉熵损失与 L_2 正则化，并完成训练、超参数搜索、测试评估、权重可视化与错例分析。实验中采用分层划分构造训练集、验证集和测试集，最终模型将图像统一缩放到 48×48，输入维度为 6912，并结合随机翻转、旋转、随机裁剪与轻度亮度对比度扰动进行训练。最终在测试集上获得 **73.46%** 的分类准确率，相比基线模型的 **61.38%** 提升了约 **12.07** 个百分点。结果表明，在不使用卷积结构的前提下，通过扩大输入分辨率、增加模型容量并引入数据增强与动量优化，可以显著提升三层 MLP 对遥感图像颜色与粗纹理模式的建模能力，但在 Highway、HerbaceousVegetation、PermanentCrop 等类别上仍存在一定混淆。

1　任务概述

本次作业的目标是在不依赖 PyTorch、TensorFlow、JAX 等自动微分框架的前提下，从零实现一个三层神经网络分类器，在 EuroSAT 遥感图像数据集上完成 10 类地表覆盖分类。根据作业要求，实验系统至少需要包含以下五个模块：

1. 数据加载与预处理；
2. 模型定义；
3. 训练循环；
4. 测试评估；
5. 超参数搜索。

本项目的代码实现位于 `src/` 目录下，核心模块包括 `autograd.py`、`dataset.py`、`model.py`、`train.py`、`test.py` 与 `search.py`。

2 数据集与预处理

2.1 数据集

EuroSAT RGB 数据集共包含 10 个类别,类别顺序按文件夹名称排序为:`AnnualCrop`、`Forest`、`HerbaceousVegetation`、`Highway`、`Industrial`、`Pasture`、`PermanentCrop`、`Residential`、`River`、`SeaLake`。

实验中采用分层随机划分，比例为 70% / 15% / 15%。实际划分结果为:

- 训练集：18900 张;
- 验证集：4050 张;
- 测试集：4050 张。

2.2 预处理流程

在最终提交模型中，实验将原始 RGB 图像统一缩放到 48×48。之后对训练集像素计算通道均值与标准差，对全部样本进行标准化，并将图像展平为一维向量作为 MLP 输入，因此每个样本的输入维度为:

$$d = 48 \times 48 \times 3 = 6912. \tag{1}$$

整个预处理流程如下:

1. 读取图像并转换为 RGB;
2. 缩放到 48×48;
3. 将像素值归一化到 $[0, 1]$;
4. 使用训练集统计量做逐通道标准化;
5. 在训练阶段加入随机水平/垂直翻转、90° 旋转、随机裁剪与轻度亮度对比度扰动;
6. 将图像展平成长度为 6912 的向量。

3 模型与方法

3.1 自动微分实现

项目自行实现了一个轻量级 `Tensor` 类，支持计算图构建、拓扑排序和反向传播。目前实现了加法、减法、乘法、除法、矩阵乘法、求和以及 ReLU、Tanh、Sigmoid 等操作，并在反向传播阶段自动累积梯度。这使得训练过程无需依赖现成深度学习框架的自动微分机制。

3.2 三层 MLP 结构

本实验使用三层全连接网络：

$$h_1 = \phi(W_1 x + b_1), \quad h_2 = \phi(W_2 h_1 + b_2), \quad z = W_3 h_2 + b_3, \tag{2}$$

其中 $\phi(\cdot)$ 为激活函数，z 为类别 logits。模型支持在 ReLU、Tanh、Sigmoid 之间切换；在最终最佳配置中，采用的是 ReLU。

3.3 损失函数与优化

训练阶段采用 Softmax 交叉熵损失：

$$\mathcal{L}_{ce} = -\frac{1}{N}\sum_{i=1}^{N} \log \frac{e^{z_{i,y_i}}}{\sum_c e^{z_{i,c}}}. \tag{3}$$

参数更新使用带动量的 SGD（momentum = 0.9），并在权重梯度中显式加入 L_2 正则项（Weight Decay）：

$$\theta \leftarrow \theta - \eta \left(\nabla_\theta \mathcal{L}_{ce} + \lambda\theta\right). \tag{4}$$

学习率衰减采用 Step LR 调度器：每经过 10 个 epoch，将学习率乘以 0.5。此外，程序会在验证集准确率提升时自动保存当前最优模型权重。

4 实验设置

4.1 基线模型

基线模型的配置如下：

- 图像尺寸：32×32；
- 隐藏层维度：`[128, 64]`；
- 激活函数：ReLU；
- 学习率：0.01；
- Weight Decay：10^{-4}；
- 训练轮数：30。

4.2 超参数搜索

为了得到更优配置，实验进行了 8 组随机搜索，候选空间如下：

- 学习率：{0.1, 0.03, 0.01, 0.003}；
- 隐藏层维度：{[128,64], [256,128]}；
- Weight Decay：{0, 10^{-4}, 10^{-3}}；
- 激活函数：{`relu`, `tanh`}。

每组搜索训练 20 个 epoch，并以验证集最佳准确率作为模型选择标准。

Trial	LR	Hidden Dims	Weight Decay	Activation	Best Val Acc (%)
01	0.003	[128, 64]	0	tanh	52.40
02	0.01	[256, 128]	0	relu	61.56
03	0.003	[256, 128]	10^{-4}	tanh	54.15
04	0.01	[256, 128]	10^{-3}	relu	61.70
05	0.1	[128, 64]	10^{-3}	tanh	60.74
06	0.003	[256, 128]	10^{-3}	tanh	54.10
07	0.003	[256, 128]	10^{-4}	relu	56.49
08	0.01	[128, 64]	0	relu	59.85

表 1: 8 组随机搜索结果

随机搜索阶段的最佳配置为:`lr=0.01`,`hidden_dims=[256,128]`,`weight_decay=0.001`,`activation=relu`。

在此基础上，进一步结合误差分析对训练策略进行定向改进：将输入分辨率提升到 48×48，使用更宽的隐藏层 `[512,256]`，采用 He 初始化、带动量的 SGD、60 个 epoch 的更长训练，以及随机翻转、旋转、随机裁剪和亮度扰动。最终提交配置为：`lr=0.005`,`momentum=0.9`,`hidden_dims=[512,256]`,`weight_decay=0.001`,`image_size=48`,`activation=relu`,`epochs=60`。

5 实验结果

5.1 基线模型与最终模型对比

可以看到，随机搜索将测试集准确率从 61.38% 提升到 62.62%，而在进一步采用更高输入分辨率、更宽隐藏层、带动量优化与数据增强后，最终模型的测试准确率进一步提升到 73.46%，相对基线共提升约 12.07 个百分点；测试损失也从 1.086 降低到 0.737。说明对于纯 MLP，输入分辨率、模型容量和训练策略对性能有决定性影响。

模型	Hidden Dims	Weight Decay	Epochs	Best Val Acc (%)	Test Acc (%)
Baseline_32	[128, 64]	10^{-4}	30	60.10	61.38
Search_32_Best	[256, 128]	10^{-3}	20	61.70	62.62
Improved_48_Aug	[512, 256]	10^{-3}	60	72.40	73.46

表 2: 基线模型与最终模型对比

5.2 训练过程曲线

图 1 展示了最终模型的训练集损失、验证集损失和验证集准确率曲线。可以看到:

- 前 5 个 epoch 收敛最快，损失下降明显;
- 验证集准确率在 40 个 epoch 之后仍有缓慢提升，最终在第 60 个 epoch 达到 72.40%;
- 训练损失与验证损失之间存在稳定间隔，但没有出现明显发散，说明数据增强和学习率衰减在一定程度上抑制了过拟合。

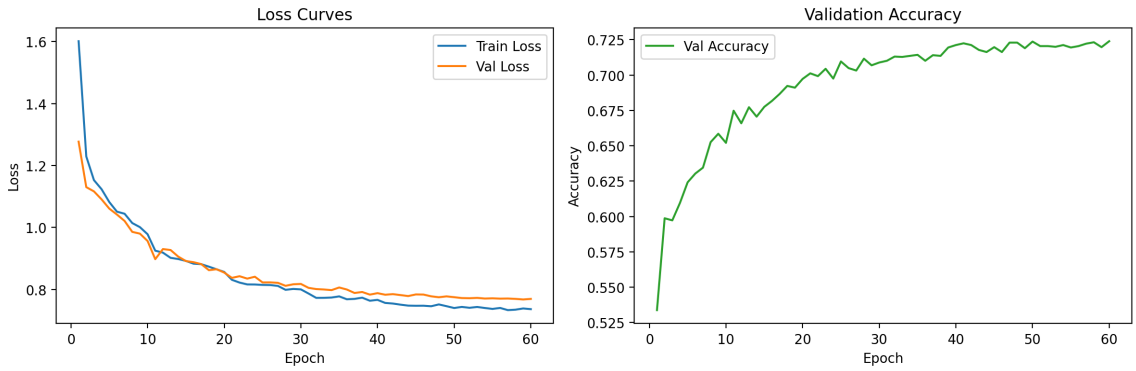

图 1: 最终模型训练曲线与验证集准确率曲线

5.3 测试集混淆矩阵

图 2 为最终模型在测试集上的混淆矩阵。从整体上看，`Industrial`、`Forest`、`Pasture`、`Residential` 和 `SeaLake` 的识别效果相对更好，而 `Highway`、`HerbaceousVegetation` 和 `PermanentCrop` 仍然更容易与其他类别混淆。

其中较明显的混淆包括:

- `HerbaceousVegetation` → `PermanentCrop`: 64;
- `Highway` → `River`: 55;
- `HerbaceousVegetation` → `Residential`: 53;

- `SeaLake` → `Forest`：46；
- `PermanentCrop` → `AnnualCrop`：32。

相比先前的 32×32 模型，这些混淆数量已有明显下降，说明更高分辨率和更强训练策略确实改善了颜色与粗纹理特征的利用效率；但纯 MLP 依然难以稳定区分结构高度相似的细分类别。

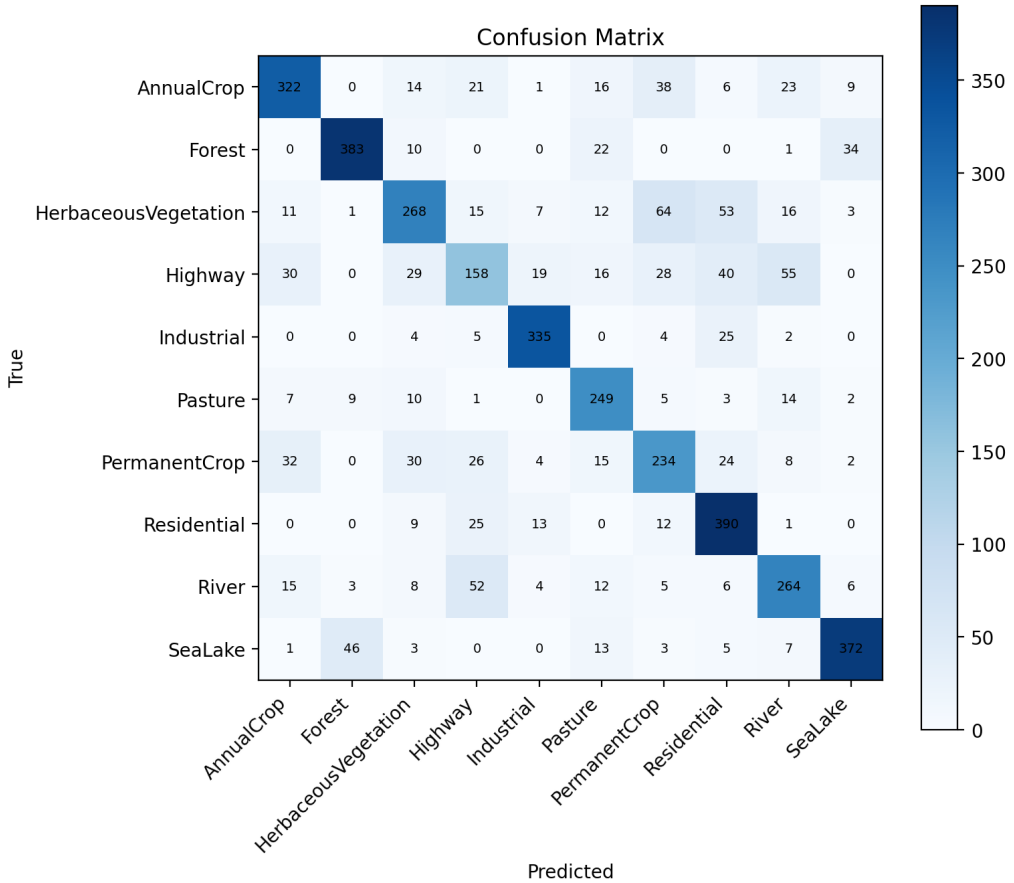

图 2: 最终模型在测试集上的混淆矩阵

6 权重可视化与空间模式观察

图 3 展示了第一层部分神经元权重恢复为图像后的可视化结果。

从可视化结果看，这些权重并没有表现出像卷积核那样清晰、规则的局部结构，而是更接近高频颜色块和细粒度噪声纹理的组合。这一现象与模型结构本身有关：MLP 在输入前先将图像展平，丢失了卷积网络常见的局部平移不变性，因此第一层权重更像是在拟合全局像素分布中的颜色对比和粗纹理统计，而不是提取稳定的局部几何模式。

尽管如此，仍可以观察到一些神经元对绿色、棕色、蓝色等通道响应较强，这说明模型确实利用了地表覆盖类别之间的颜色差异，例如：

- 绿色主导的区域有助于区分 `Forest`、`Pasture` 等植被类；
- 蓝色成分更明显的权重有助于识别 `SeaLake`、`River`；
- 棕色与灰色条带可能对应农田、道路或工业地表的纹理信息。

整体而言，第一层权重中能看到一定颜色倾向，但空间模式并不稳定，这也是 MLP 相比 CNN 在图像任务上表达能力较弱的一个直观体现。

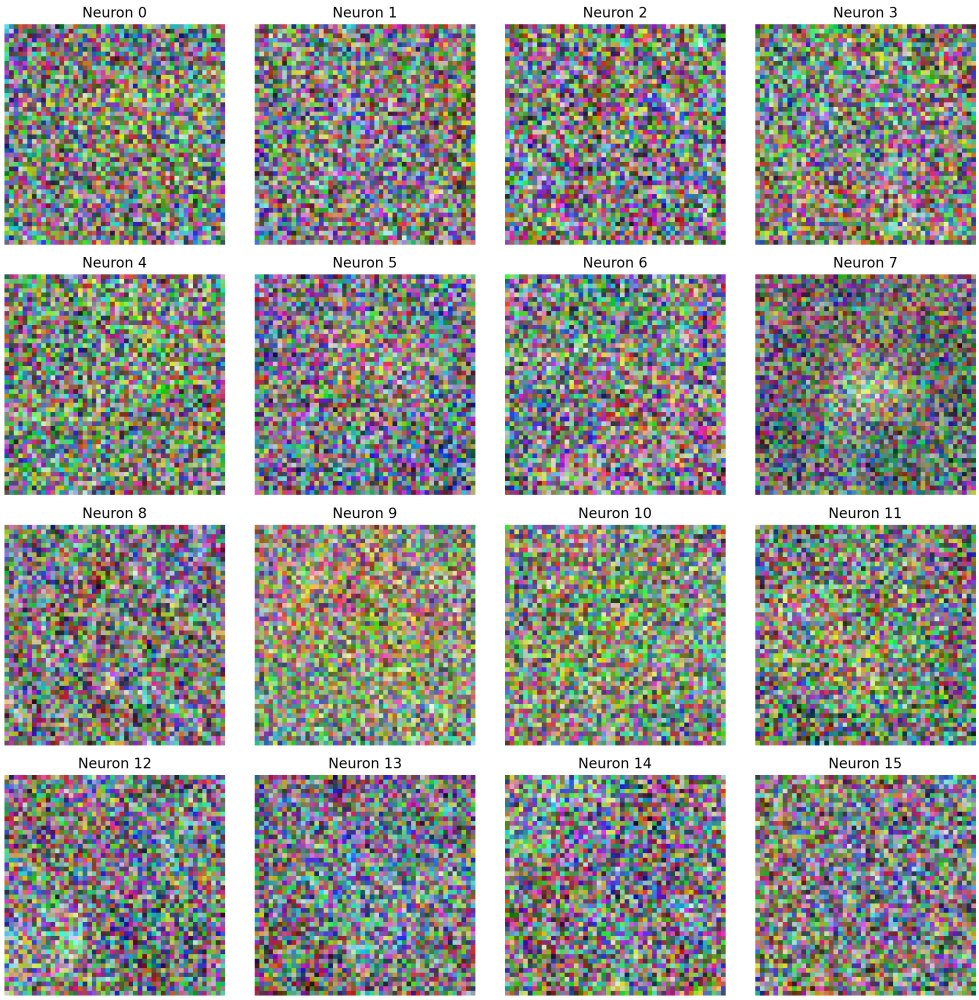

图 3: 第一层隐藏层部分权重的可视化结果

7 错例分析

图 4 给出了测试集中的部分错分样例。从这些样例可以看出，即使提升到 48×48 分辨率并引入数据增强，当多个类别同时具有相似的颜色分布、条带纹理或块状结构时，模型仍然会出现误判。

本实验中较典型的错分现象包括：

- 多张 HerbaceousVegetation 被误分为 PermanentCrop 或 Residential，说明稀疏植被、地块边界与局部人工结构在遥感视角下仍可能共享相似颜色与纹理；
- Highway 仍然容易被误分为 River 或 Residential，表明线状目标和带状分布目标之间依然存在明显外观相似性；
- AnnualCrop 与 PermanentCrop 仍有双向混淆，但相比基线数量已明显下降，说明更高分辨率确实增强了对农田纹理差异的刻画。

结合混淆矩阵来看,Highway 与 River、Residential 的混淆依旧最突出,说明在遥感视角下,线状目标和带状分布目标之间仍然具有较强外观相似性。此外,HerbaceousVegetation 与 PermanentCrop 的混淆也说明，植被类地物在没有卷积特征提取的情况下，仍较难通过简单的全连接网络完全分开。

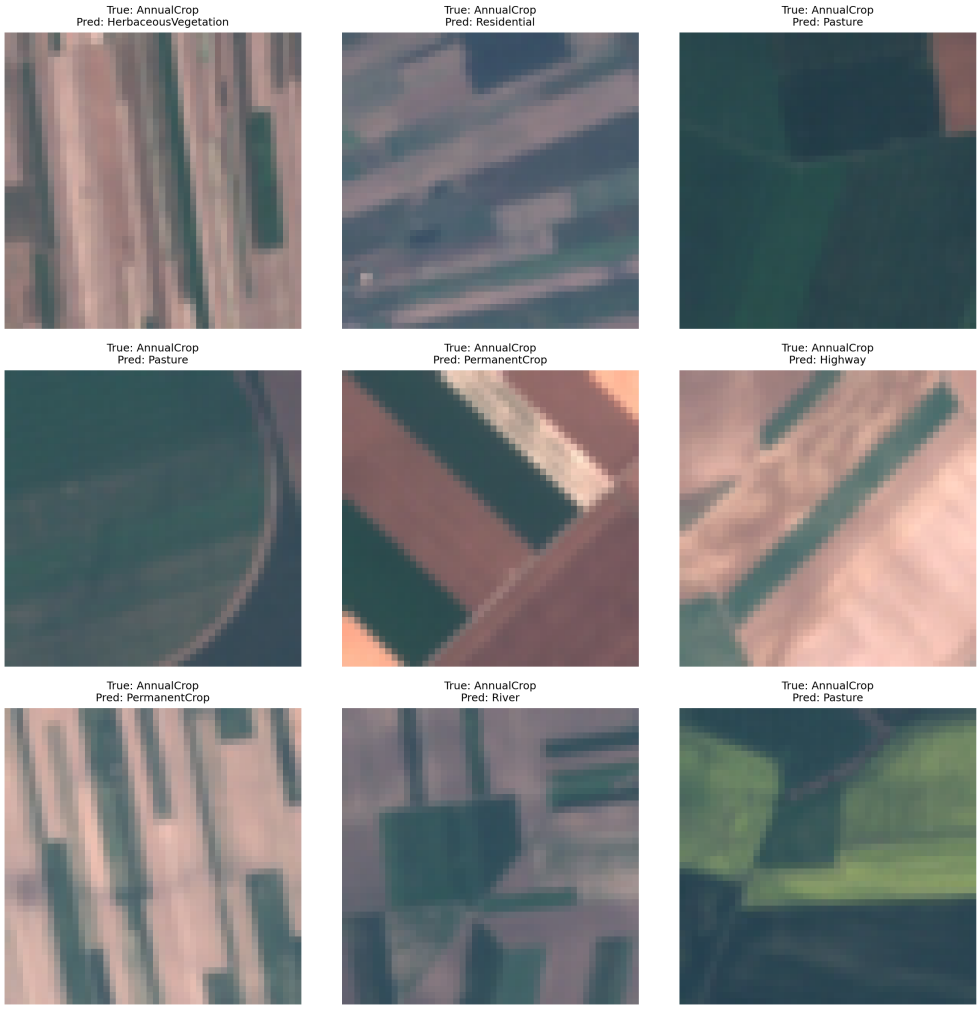

图 4: 测试集中的部分错分样例

8 结论

本实验完成了一个从零实现的三层 MLP 遥感图像分类系统，覆盖了自动微分、模型训练、超参数搜索、最优权重保存、测试评估、混淆矩阵绘制、权重可视化和错例分析等全部环节。

从实验结果看：

- 纯 MLP 在 EuroSAT 上能够达到 73.46% 的测试准确率，说明在合理训练策略下其仍具有较强的分类能力；
- 提升输入分辨率、引入数据增强、动量 SGD 和更宽隐藏层，相比固定基线带来了显著收益；
- 权重可视化与错例分析共同表明，MLP 更依赖颜色与粗纹理统计，而对复杂局部空间结构的建模能力仍然有限。

如果继续改进，较自然的方向包括：加入更强的数据增强、重新设计学习率衰减策略、尝试更大的隐藏层或更长训练、以及进一步使用更适合图像建模的卷积结构。不过在本次作业限定的三层 MLP 框架下，当前结果已经较充分地完成了任务要求。

提交信息

本次提交使用的公开链接如下：

- Public GitHub Repo：GitHub Repo
- 模型权重下载地址：Google Drive File

复现实验命令

以下命令可用于复现实验流程（根据实际目录位置调整）：

```
python -m src.train \
  --data_dir ./EuroSAT_RGB \
  --epochs 60 \
  --batch_size 128 \
  --lr 0.005 \
  --momentum 0.9 \
  --weight_decay 0.001 \
  --step_size 10 \
```

```
  --gamma 0.5 \
  --hidden_dims 512 256 \
  --activation relu \
  --image_size 48 \
  --augment \
  --min_crop_scale 0.85 \
  --brightness_jitter 0.1 \
  --run_name improved_aug48_momentum_v2_60ep

python -m src.test \
  --data_dir ./EuroSAT_RGB \
  --checkpoint ./outputs/improved_aug48_momentum_v2_60ep/checkpoints/best_model.npz \
  --run_name improved_aug48_momentum_v2_60ep_test
```